



UNIVERSIDAD  
NACIONAL  
DE COLOMBIA



# Diplomado

# BIG DATA ANALYTICS

## Análisis Predictivo

Por  
Ing. Fabio González,  
Ph.D.

# Agenda

- Análisis Predictivo
  - Clasificación
  - Evaluación de Algoritmos de Clasificación
  - Generalización y Sobre-ajuste
  - Clasificación Sensible al Costo
  - Regresión y Series de Tiempo

# Agenda

## 1. Análisis Predictivo de Datos

- Clasificación
- Evaluación de Algoritmos de Clasificación
- Generalización y Sobre-ajuste
- Clasificación Sensible al Costo
- Regresión y Series de Tiempo

# Análisis Predictivo de Datos

*Uso de algunas variables para predecir valores desconocidos o futuros de otras variable*

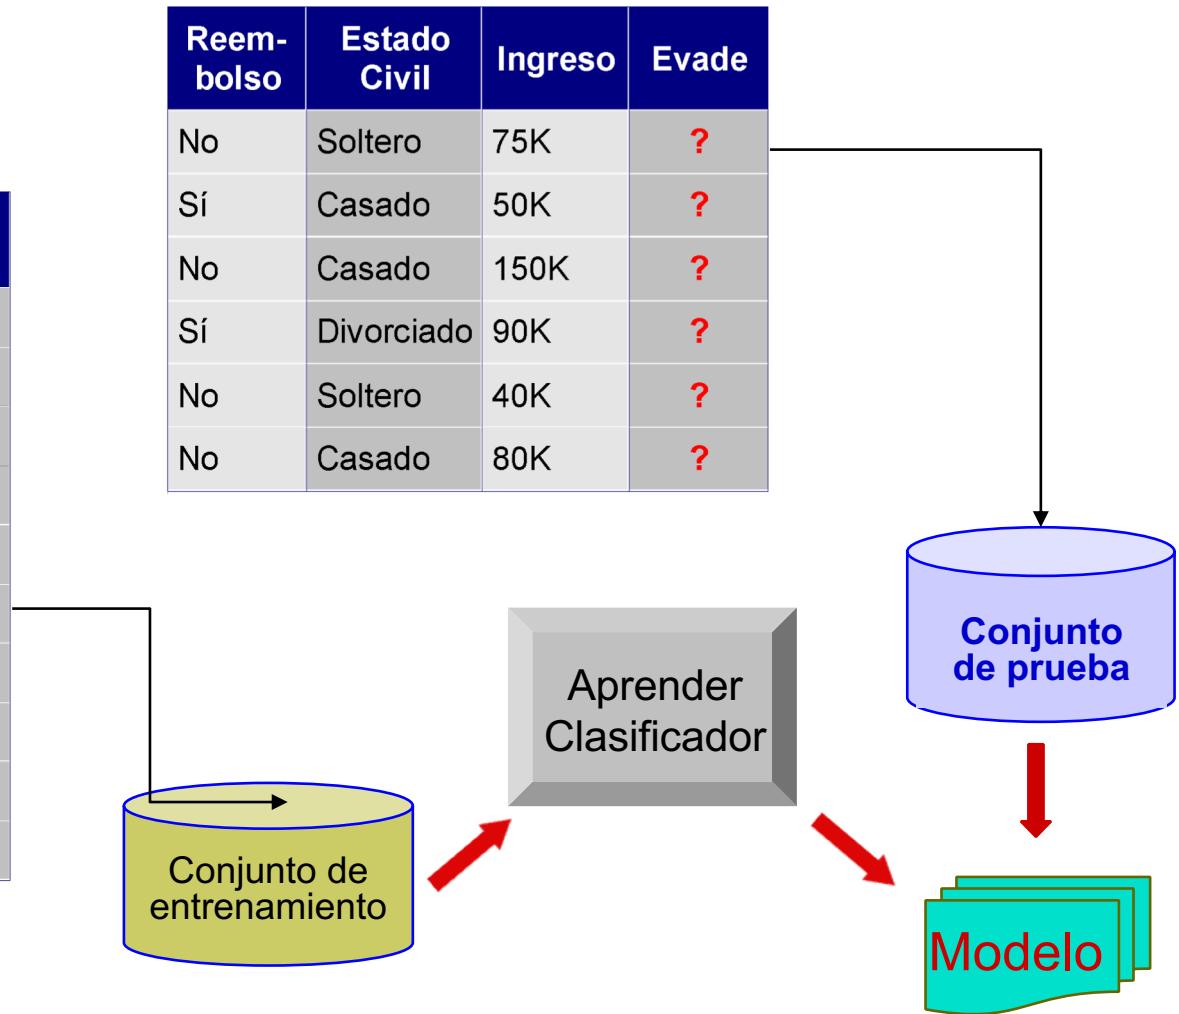
# Clasificación

- Dada una colección de registros (***conjunto de entrenamiento***)
  - Cada registro contiene un conjunto de ***atributos***, uno de ellos es la ***clase***
- Encontrar un modelo para el atributo de clase como una función de los valores de los atributos
- Objetivo: asignar una clase lo más preciso posible a los registros que no se han visto antes
  - Un ***conjunto de prueba*** es usado para determinar la exactitud del modelo. A menudo se divide el conjunto de datos en conjuntos de entrenamiento (construcción del modelo) y de prueba (validación)

# Clasificación

Tid	categorico		categorico		Continuo
	Reem-bolso	Estado Civil	Ingreso	Evade	
1	Sí	Soltero	125K	No	
2	No	Casado	100K	No	
3	No	Soltero	70K	No	
4	Sí	Casado	120K	No	
5	No	Divorciado	95K	Sí	
6	No	Casado	60K	No	
7	Sí	Divorciado	220K	No	
8	No	Soltero	85K	Sí	
9	No	Casado	75K	No	
10	No	Soltero	90K	Sí	

Reem-bolso	Estado Civil	Ingreso	Evade
No	Soltero	75K	?
Sí	Casado	50K	?
No	Casado	150K	?
Sí	Divorciado	90K	?
No	Soltero	40K	?
No	Casado	80K	?



# Clasificación: Aplicación 1

- Marketing Directo
  - Objetivo: Reducir el costo de envío de correo al *enfocarse* en los clientes que probablemente compren el nuevo producto
  - Enfoque:
    - Usar datos de un producto similar que se haya lanzado antes
    - Sabemos cuáles clientes decidieron comprar y cuáles no. Esta decisión *{compra, no compra}* forma el *atributo de clase*
    - Reunir información demográfica, del estilo de vida o económica de estos compradores
      - Tipo de negocio, donde viven, cuanto ganan, etc
    - Usar esta información como variables de entrada para construir el modelo de clasificación

# Clasificación: Aplicación 2

- Detección de Fraudes
  - Objetivo: Predecir casos fraudulentos en transacciones de tarjeta de crédito.
  - Enfoque:
    - Usar las transacciones y la información sobre los titulares de la cuenta como los atributos
      - Cuándo compra un cliente, qué compra, qué tan a menudo paga a tiempo, etc
    - Etiquetar las transacciones pasadas como fraude o correcta. Con esto se crea el atributo de clase.
    - Construir un modelo para la clase de transacción Tipo de negocio, donde viven, cuanto ganan, etc
    - Usar el modelo para detectar fraudes observando las transacciones de una tarjeta de crédito

# Clasificación: Aplicación 3

- Pérdida/Cancelación de Clientes:
  - Objetivo: Predecir si es probable que se pierda un cliente frente a un competidor
  - Enfoque:
    - Usar registros detallados de transacciones de clientes antiguos y actuales para hallar atributos
      - Qué tan frecuente llama el cliente, dónde llama, a qué hora hace la mayoría de llamadas, estado financiero, estado civil, etc.
    - Etiquetar los clientes como leal o desleal
    - Encontrar un modelo para la lealtad

# Clasificación: Aplicación 4

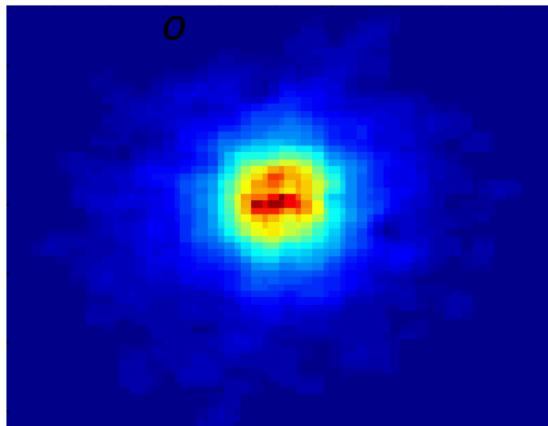
- Pérdida/Cancelación de Clientes
  - Objetivo: Predecir la clase (estrella o galaxia) de los objetos del cielo, especialmente aquellos apenas visibles, con base en las imágenes de telescopio (desde el Observatorio Palomar ).
    - 3000 imágenes con 23,040 x 23,040 píxeles por imagen
  - Enfoque:
    - Usar registros detallados de transacciones de clientes antiguos y actuales para hallar atributo
    - Segmentar la imagen
    - Medir los atributos de la imagen (características) - 40 por objeto
    - Modelar la clase con base en estas características
    - Historia de éxito: Se encontraron 16 nuevos cuásares con alto desplazamiento al rojo, unos de los objetos más lejanos que son difíciles de encontrar!

# Clasificación: Aplicación 5

- Clasificando galaxias

*Tempran*

o



Clase:

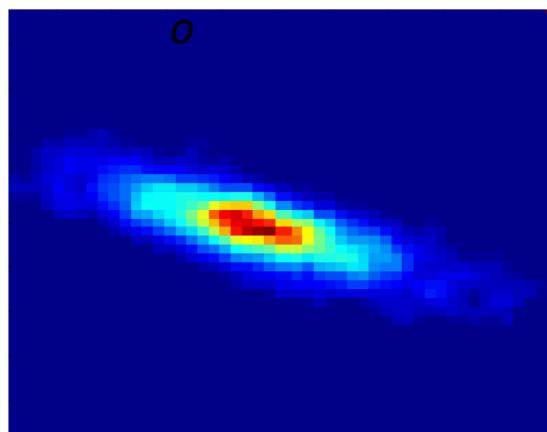
- Estados de Formación

Atributos:

- Características de la Imagen,
- Características de ondas de luz recibidas, etc.

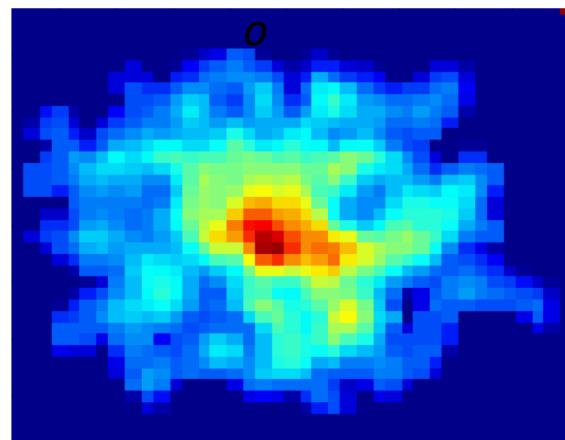
*Intermedi*

o



*Tardí*

o

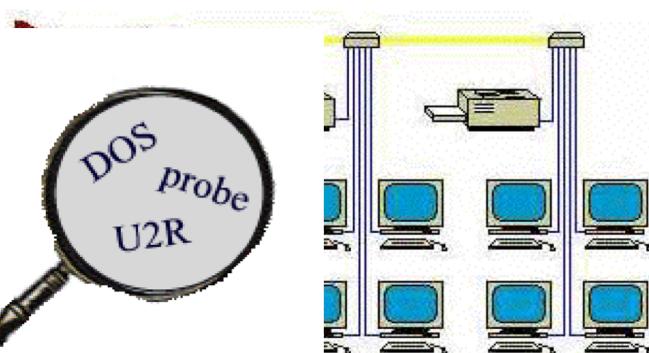
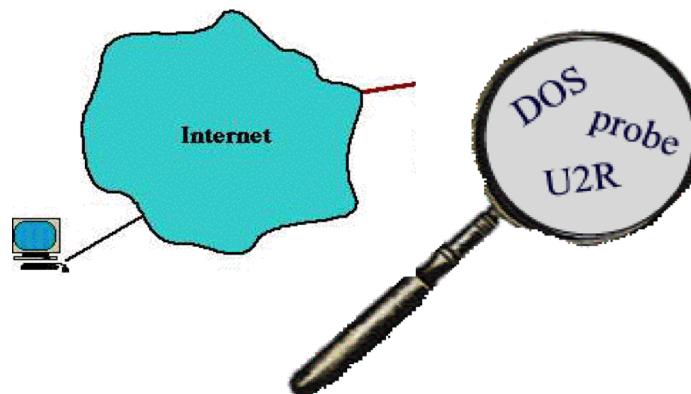


Tamaño de los datos:

- 72 millones de estrellas, 20 millones de galaxias
- Catálogo de Objetos: 9 GB
- Base de Datos de Imágenes: 150 GB

# Clasificación: Aplicación 6

- Detectar desviaciones significativas del comportamiento normal
- Aplicaciones:
  - Detección de fraude en tarjetas de crédito
  - Detección de intrusos en redes de computadores



# Agenda

## 1. Análisis Predictivo de Datos

- Clasificación
- Evaluación de Algoritmos de Clasificación
- Generalización y Sobre-ajuste
- Clasificación Sensible al Costo
- Regresión y Series de Tiempo

# Evaluación de Algoritmos

- Criterios (dependiendo de la aplicación):
  - Error de clasificación o riesgo
  - Complejidad espacio/temporal del entrenamiento
  - Complejidad espacio/temporal de la aplicación
  - Interpretabilidad
  - Programación sencilla

# Matrices de Confusión



- Usadas cuando más de dos clases están involucradas

		Clase Predicha		
		Setosa	Virginica	Versicolor
Clase verdadera	Setosa	50	0	0
	Virginica	0	48	2
Versicolor	0	1	49	

# Medidas de Error

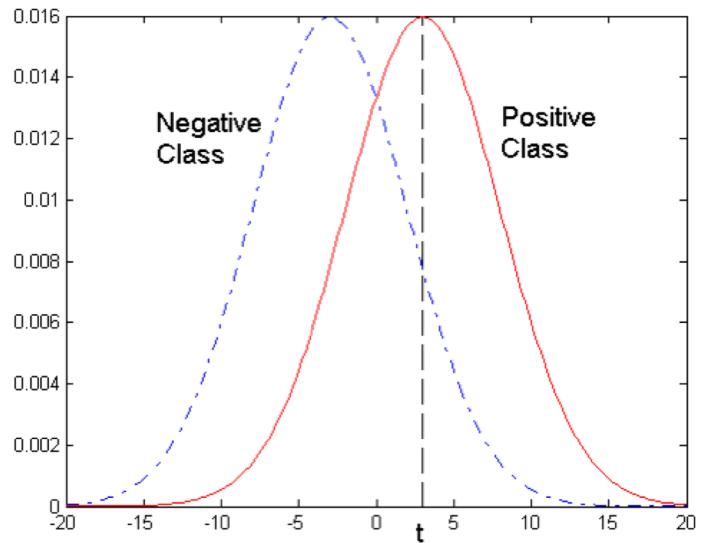
		Clase Predicha	
Clase verdadera		+	-
+	True Positive	False Negative	
-	False Positive	True Negative	

- **%error** = #errores/#instancias =  $(FN+FP)/N$
- **sensitividad** = #+ encontrados/#+ =  $TP/(TP+FN)$  (recall, hit rate)
- **precisión** = #+ encontrados/ #total de encontrados =  $TP/(TP+FP)$
- **especificidad** =  $TN/(TN+FP)$
- **%falsas alarmas** =  $FP/(FP+TN)$

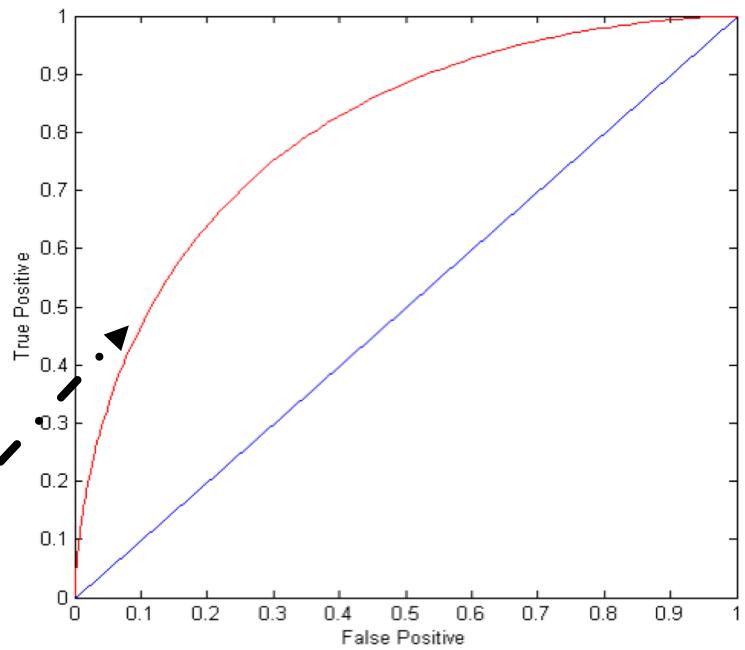
# Curvas ROC

- Caracteriza el umbral entre hits positivos y falsas alarmas
- La curva ROC modela los TP en el eje Y, contra los FP en el eje X
- El comportamiento de cada clasificador es representado como un punto en la curva ROC

# Curvas ROC



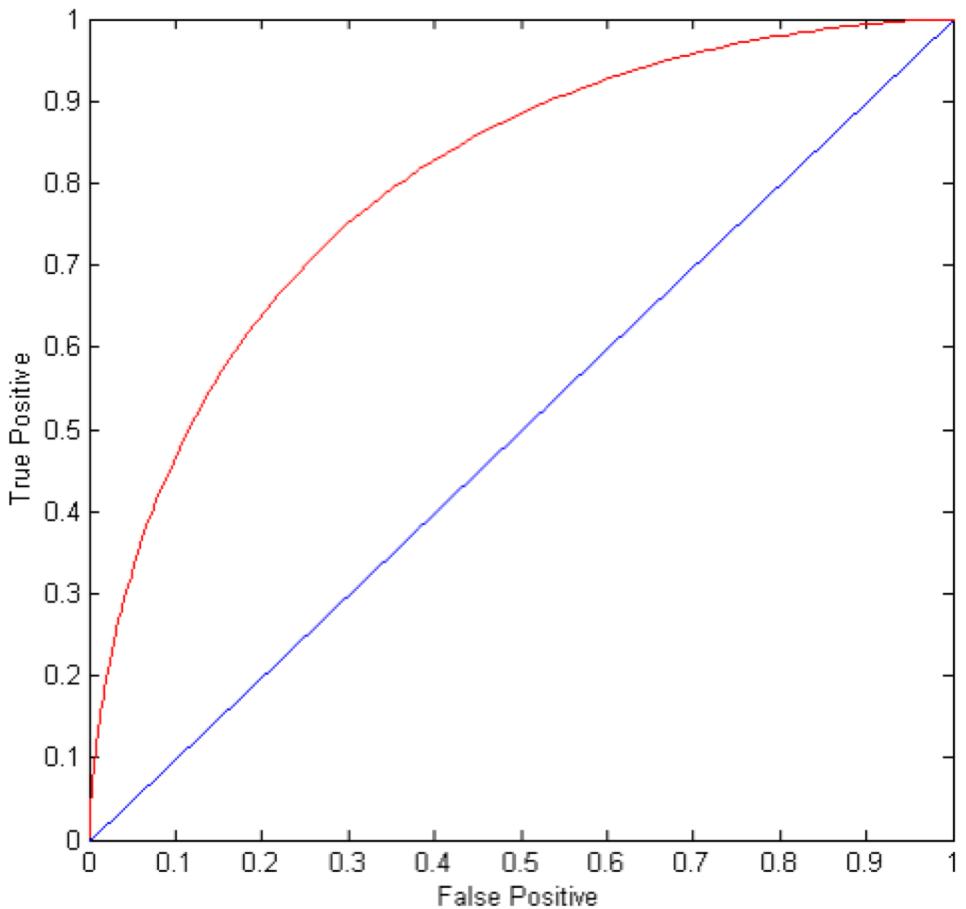
At threshold  $t$ :  
 $TP=0.5$ ,  $FN=0.5$ ,  $FP=0.12$ ,  $FN=0.88$



# Curvas ROC

(TP,FP):

- (0,0): Declara todo para ser clase negativa
- (1,1): Declara todo para ser clase positiva
- (1,0): Ideal
- Línea diagonal: Suposición



# Métodos de Estimación



- **Holdout**

- Mantener un porcentaje de instancias (2/3) para entrenamiento y el resto (1/3) para pruebas
- Se sugiere que el de entrenamiento sea mayor que el de pruebas

- **Muestreo Aleatorio**

- Repetir varias veces holdout y calcular estadísticos sobre dicho proceso
- Se sugiere repetir como mínimo 30 veces

- **Validación Cruzada (Cross validation)**

- Partir el conjunto de datos en k subgrupos disjuntos
- k-fold: entrenar con  $k-1$  subgrupos, validar con el restante. Repetir usando cada grupo en validación
- Dejar uno afuera (Leave-one-out):  $k=n$

- **Muestreo Estratificado**

- sobremuestreo vs submuestreo

- **Bootstrap**

- Muestreo con repetición

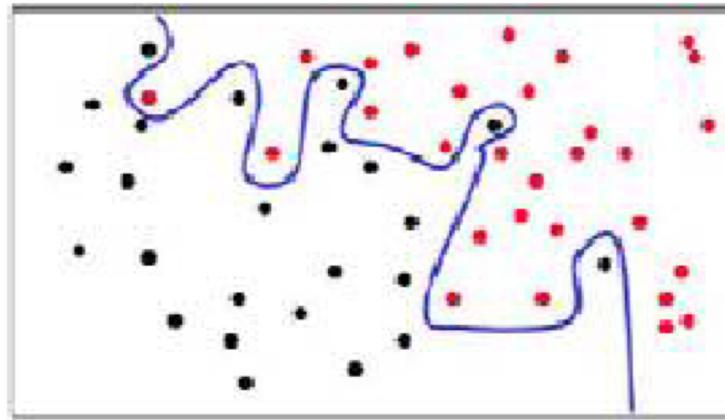
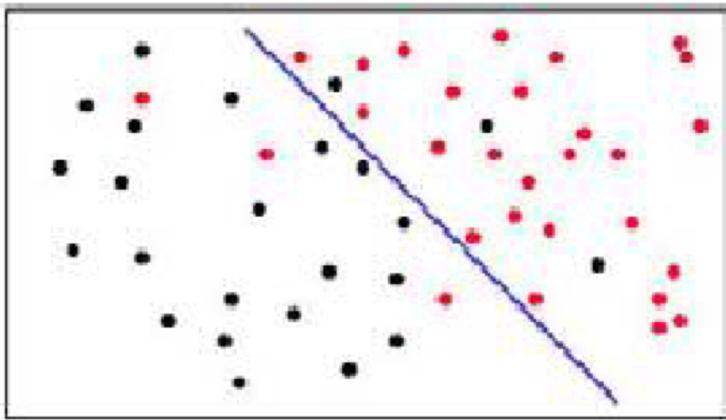
# Agenda

## 1. Análisis Predictivo de Datos

- Clasificación
- Evaluación de Algoritmos de Clasificación
- Generalización y Sobre-ajuste
- Clasificación Sensible al Costo
- Regresión y Series de Tiempo

# Sobre-ajuste (Overfitting)

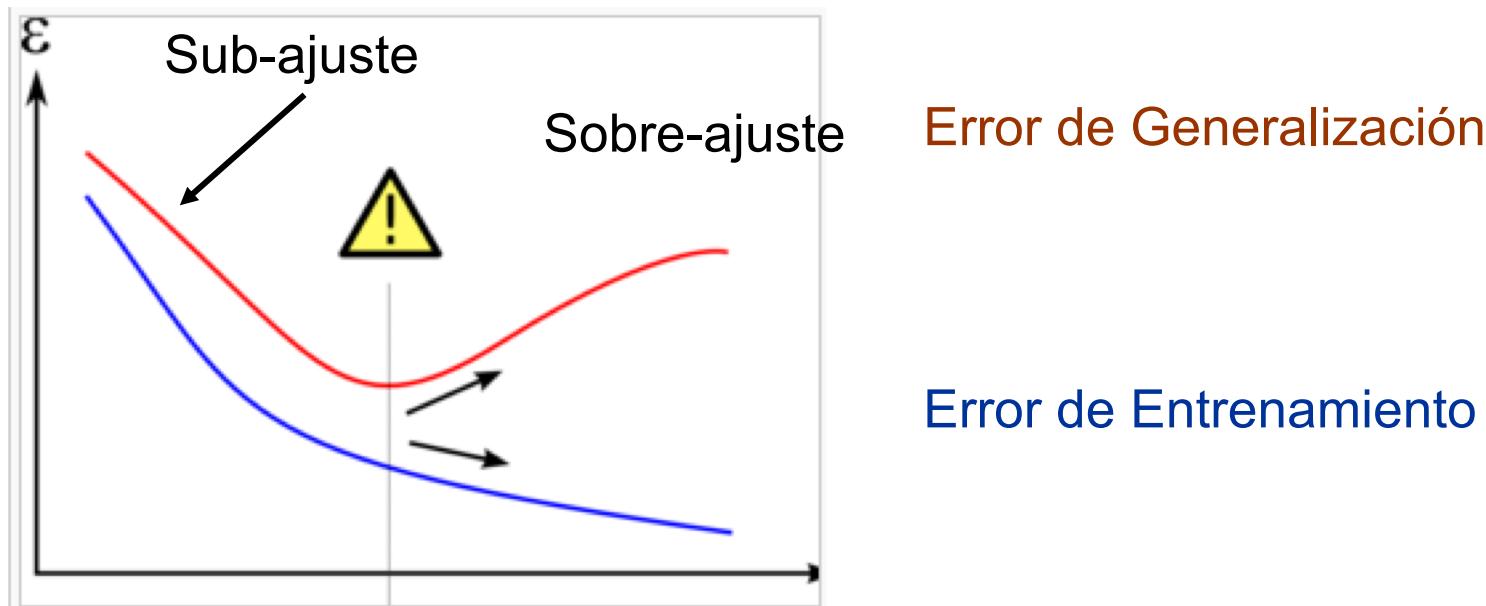
- Cuando el algoritmo de aprendizaje se ajusta tanto a los datos de entrada que pierde su capacidad de generalizar



- El error de cálculo de los ejemplos futuros será alto

# Sobre-ajuste (Overfitting)

- **Sobre-ajuste:** Bajo error de entrenamiento pero error de generalización alto.
- **Sub-ajuste (underfitting):** Errores de entrenamiento y generalización altos



# Sobre-ajuste (Overfitting)

- Ejemplo

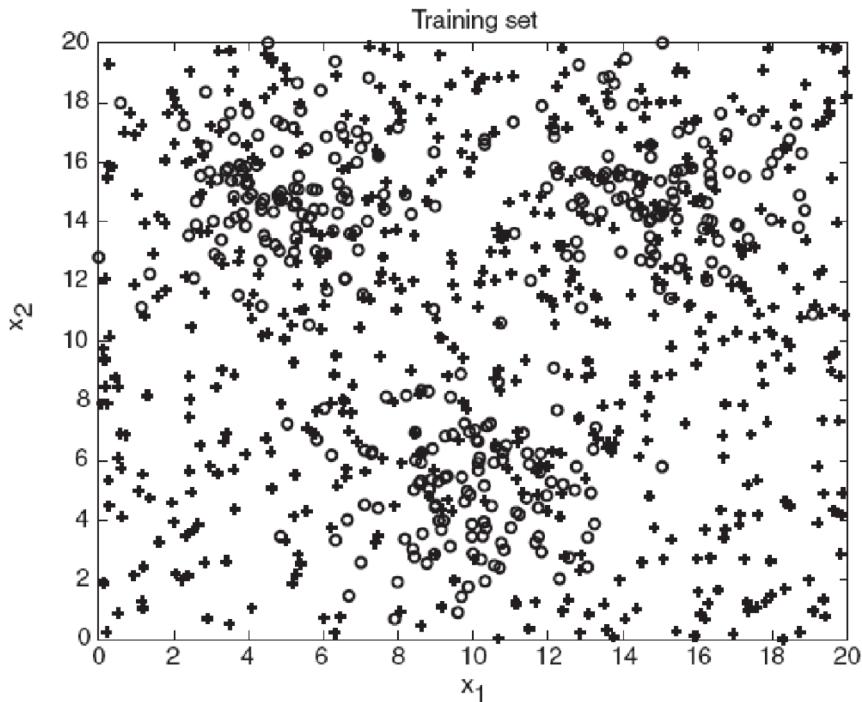


Figure 4.22. Example of a data set with binary classes.

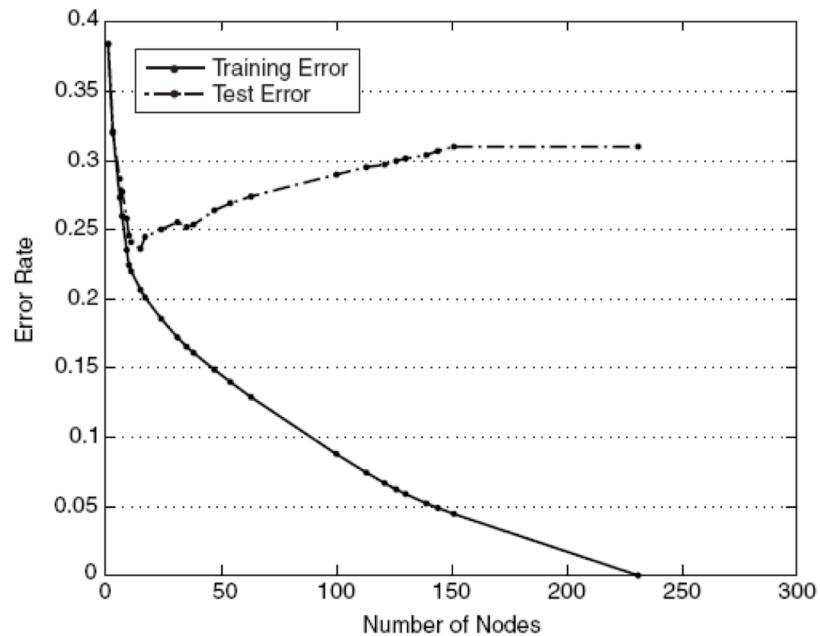
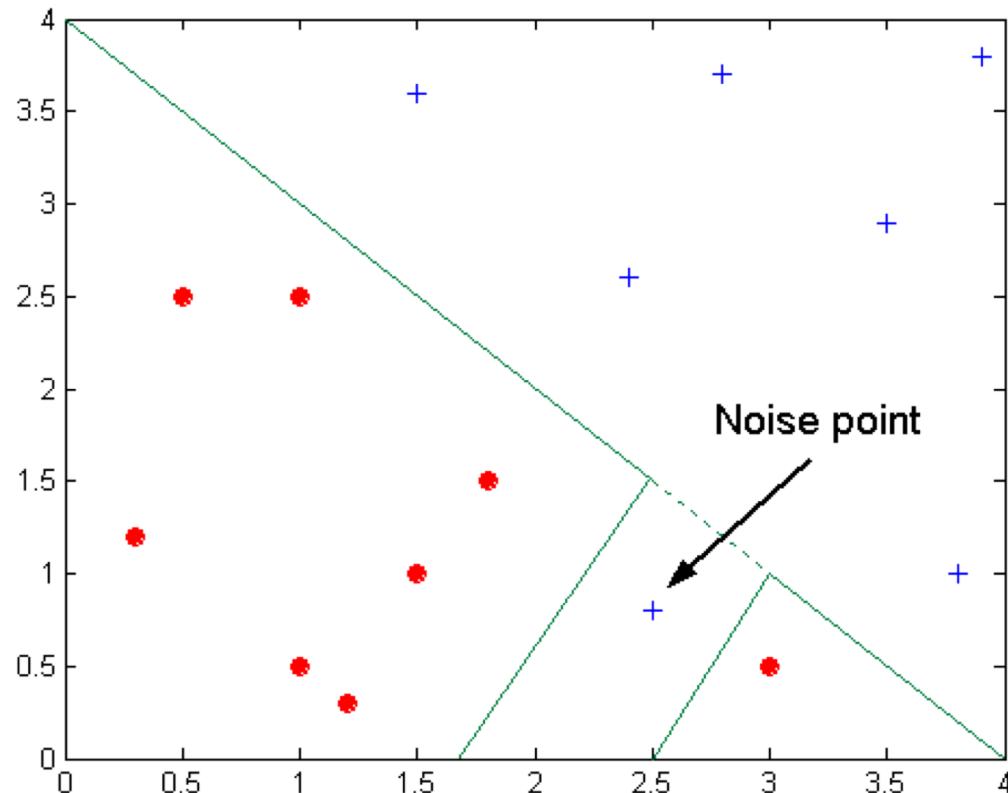


Figure 4.23. Training and test error rates.

# Sobre-ajuste (Overfitting)

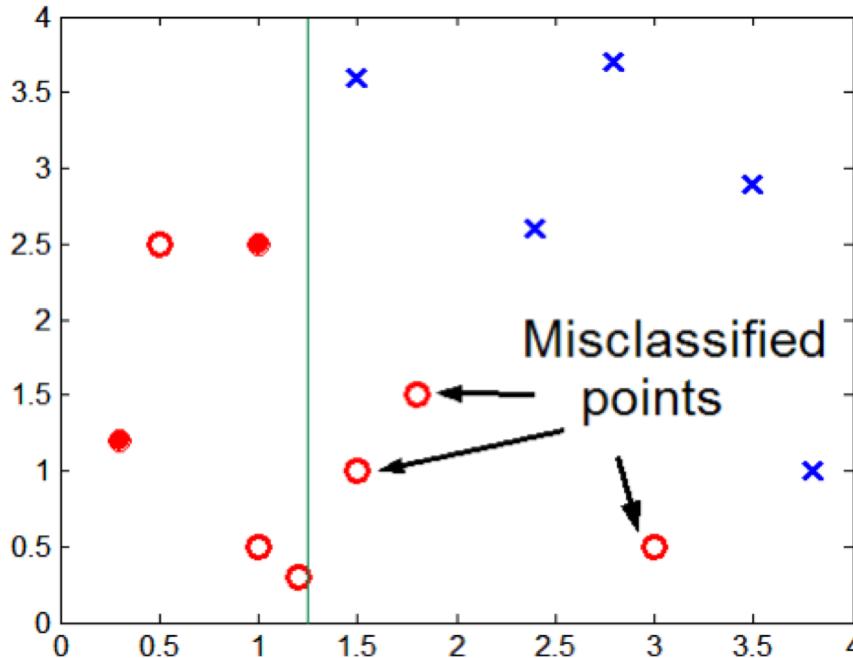
- Presencia de ruido



La frontera de decisión es distorsionada por el ruido

# Sobre-ajuste (Overfitting)

- Falta de ejemplos representativos



La falta de ejemplos en la parte inferior del diagrama hace difícil que el modelo realice una predicción acertada en esta región

# Error de Clasificación

- Error de entrenamiento:
  - $e(\text{modelo, datos})$
  - Número de ejemplos de entrenamiento clasificados incorrectamente
  - Conocido como error de re-substitución o error aparente
- Error de generalización:
  - $e'(\text{modelo, datos})$
  - Error esperado del modelo en ejemplos no usados en el entrenamiento
- Un buen modelo debe tener errores de entrenamiento y generalización bajos

# Estimación del Error de Generalización

- Estimación optimista: Usando re-substitución

$$e'(\text{modelo, datos}) = e(\text{modelo, datos})$$

- Incorporando la complejidad del modelo – Cuchilla de Occam

$$e'(\text{modelo, datos}) = e(\text{modelo, datos}) + \text{costo}(\text{modelo, datos})$$

- Estimación pesimista
- Principio MDL (Descripción de mínima longitud)

# Complejidad del Modelo

- Parámetro que controla lo complejo del modelo
- En árboles de decisión (tamaño)
  - Pre-podado
  - Post-podado
- En redes neuronales
  - Número neuronas ocultas y/o conexiones
  - Tipo de red neuronal

# Agenda

## 1. Análisis Predictivo de Datos

- Clasificación
- Evaluación de Algoritmos de Clasificación
- Generalización y Sobre-ajuste
- Clasificación Sensible al Costo
- Regresión y Series de Tiempo

# Costo

Área	Ejemplo
Marketing	Comprador / no Comprador
Medicina	Enfermo / no Enfermo
Finanzas	Prestar / no Prestar
Spam	Spam / no Spam

- Suponer que los errores son igualmente costosos puede llevar a malas decisiones

## Examples

**Marketing**

El costo de hacerle una oferta a un no comprador es pequeña comparada con no contactar un comprador

**Finance**

El costo de un mal prestamo es mayor que negarle un prestamo aun buen cliente

**Spam**

Rechazar correo que no sea Spam es más costoso que aceptar correo Spam

# Matriz de Costos

		Actual		
		Sunny	Snowy	Rainy
Predicted	Sunny	0	10	15
	Snowy	1	1	11
	Rainy	2	2	2

# Matriz de Costos

- Costos dependientes. Fraude con tarjeta de crédito

		Real	
		Fraude	No fraude
Predicho	Rechazo	20	- 20
	Aprobar	- $X$	(0.2) $X$

$x = \text{valor transacción}$

# Aprendizaje Sensitivo al Costo

- Aprendizaje no sensitivo al costo:

$$\max_{C_i} P(C_j | A_1, \dots, A_n)$$

- Aprendizaje sensitivo al costo:

- Escoger acción que minimice el costo esperado

$$\min_{C_i} \sum_{C_j \neq C_i} P(C_j | A_1, \dots, A_n) \text{Costo}(C_j, C_i)$$

- $\text{Costo}(C_j, C_i) = \text{costo de clasificar como } C_i \text{ cuando realmente es } C_j$

- Los dos enfoques son equivalentes cuando los costos son iguales para todos los errores

# Metacost

- Es una algoritmo que permite volver cualquier clasificador sensitivo al costo
- Se debe especificar una matriz de costos
- El algoritmo reetiqueta los ejemplos de entrenamiento de manera que el costo esperado se minimice

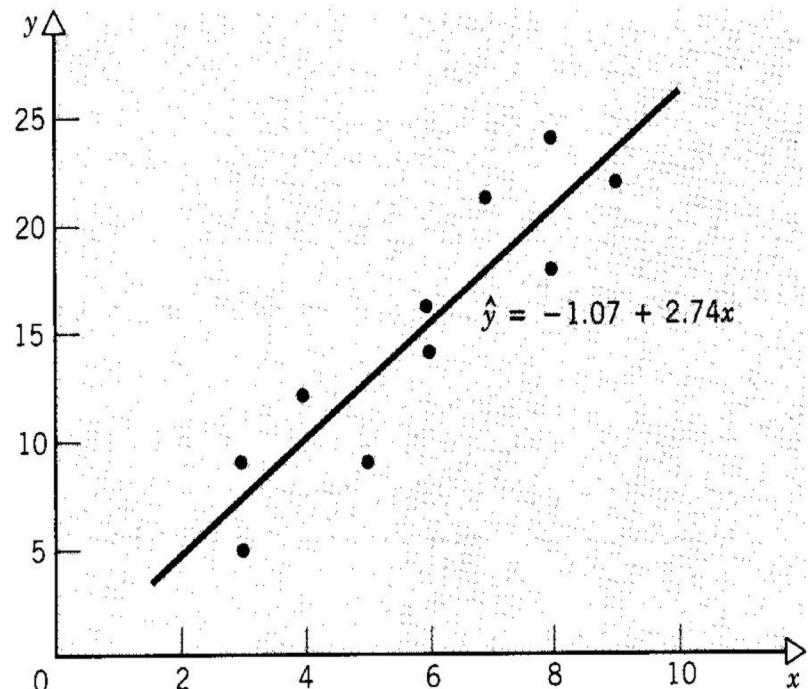
# Agenda

## 1. Análisis Predictivo de Datos

- Clasificación
- Evaluación de Algoritmos de Clasificación
- Generalización y Sobre-ajuste
- Clasificación Sensible al Costo
- Regresión y Series de Tiempo

# Regresión

- Similar al problema de clasificación pero el atributo de clase es continua
- Problema: Encontrar una relación funcional entre una variable dependiente y uno o varias variables independientes
- Tipos:
  - Regresión lineal
  - Regresión no lineal
  - Otros: regresión logística, árboles de decisión



# Series de Tiempo

- Base de Datos de Series de Tiempo
  - Consiste en secuencias de valores o eventos que cambian con el tiempo
  - Los datos son almacenados en **intervalos regulares**
  - Componentes principales de una serie de tiempo:
    - Tendencia, ciclo, estacional, irregular
- Aplicaciones
  - Finanzas: inventarios, precio, inflación
  - Industria: consumo de energía
  - Ciencia: resultados de experimentos
  - Metereología: precipitación

# Referencias

- Pang-Ning Tan, Michael Steinbach, Vipin Kumar, 2005, Introduction to Data Mining, Addison-Wesley
- Stuart Russell and Peter Norvig “Artificial Intelligence: A Modern Approach”, Second Edition.
- Domingos. *MetaCost: A General Method for Making Classifiers Cost-Sensitive*. In Proceedings of the Fifth International Conference on Knowledge Discovery and Data Mining (KDD-99). 1999.
- Alan Abrahams, An Introduction to Cost-Sensitive Learning , Lecture Slides, [http://opim.wharton.upenn.edu/~asa28/opim\\_410\\_672\\_spring05/opim\\_410\\_guest\\_lecture\\_dan\\_fleider\\_cost\\_sensitive\\_learning.ppt](http://opim.wharton.upenn.edu/~asa28/opim_410_672_spring05/opim_410_guest_lecture_dan_fleider_cost_sensitive_learning.ppt)

# ¿Preguntas?

fagonzalezo@unal.edu.co

<http://www.mindlaboratory.org>



UNIVERSIDAD  
**NACIONAL**  
DE COLOMBIA  
SEDE BOGOTÁ D.C.